فاین‌تیون ParsBERT برای دسته‌بندی اخبار فارسی

گزارش کارهای انجام‌شده، نتیجه‌ها و درس‌ها — مهر ۱۴۰۵ — کد در شاخهٔ `claude/loving-einstein-jh2u6g` ـ ریپوی `parsajafarpoor/ParsBERT-`

88.8%	0.888	0.846	17%
دقت مدل نهایی روی val	Macro-F1 مدل نهایی	Macro-F1 مدل پایهٔ TF-IDF	دقت حدس تصادفی

۱. هدف

مدل زبانی فارسی **ParsBERT** را فاین‌تیون کردیم تا خلاصهٔ یک خبر فارسی را بخواند و دستهٔ آن را تشخیص دهد: **اقتصاد، بین‌الملل، ورزش، علم و فناوری، سیاست، سلامت**. خروجی نهایی فایل `predictions.csv` با ستون‌های `id,label` برای ۱۲۰۰ خبر test است.

۲. داده

زیرمجموعه‌ای متعادل از دیتاست **PN-Summary** (تیم Hooshvare، مجوز MIT). هر نمونه خلاصهٔ یک یا دو جمله‌ای یک خبر است.

فایل	تعداد	برچسب	کاربرد
train.csv	3,000	دارد (۵۰۰ از هر کلاس)	آموزش مدل
val.csv	600	دارد (۱۰۰ از هر کلاس)	ارزیابی و انتخاب تنظیمات
test.csv	1,200	ندارد	پیش‌بینی نهایی

- **کلاس‌ها کاملاً متعادل‌اند**؛ پس دقت معیار قابل اعتمادی است.
- **داده تمیز است**: بدون مقدار خالی یا ردیف تکراری، بدون «ي/ك»ِ عربی، همهٔ عددها فارسی.

۳. توکنایزر

بررسی	نتیجه (از خروجی کد)
«مدل‌های زبانی بزرگ، متن‌های فارسی را بهتر از گذشته می‌فهمند.»	۱۶ توکن با [CLS] و [SEP]
نیم‌فاصلهٔ «مدل‌های»	حذف می‌شود و «مدلهای» یک توکن است
«دانش‌آموزان»	`[CLS] [UNK] [SEP]` — کل کلمه ناشناخته می‌شود
طول توکنی متن‌های train	کمترین ۱۳، میانه ۳۲، میانگین ۳۳٫۶، صدک ۹۹ برابر ۶۹، بیشترین ۱۶۷
متن‌های بریده‌شده	با max_length=۱۲۸ فقط ۱ متن؛ با ۶۴، ۵۲ متن (۱٫۷٪)

با وجود نام «zwnj»، توکنایزر نیم‌فاصله را در مرحلهٔ پاک‌سازی متن حذف می‌کند. برای بیشتر کلمه‌ها مشکلی پیش نمی‌آید، ولی برخی کلمه‌ها مثل «دانش‌آموزان» کاملاً به [UNK] تبدیل می‌شوند و اطلاعاتشان از دست می‌رود.

۴. روش: فاین‌تیون

ParsBERT یک Transformer با **۱۱۸,۳۰۱,۹۵۸** پارامتر است که از قبل با بازی «کلمهٔ جاافتاده را حدس بزن» روی متن فارسی آموزش دیده. در فاین‌تیون، سرِ حدس کلمه (`cls.predictions`) کنار گذاشته می‌شود و یک سر طبقه‌بندی تازه با ۶ خروجی (**۴,۶۱۴** ، `classifier` پارامتر = ۶+۶×۷۶۸) اضافه می‌شود. در این checkpoint لایهٔ pooler (۵۹۰,۵۹۲ پارامتر) هم وجود ندارد و تصادفی ساخته می‌شود. سپس کل مدل با دادهٔ ما آموزش می‌بیند.

پیش از آموزش، loss اعتبارسنجی **۱٫۸۰۹** بود، تقریباً برابر **۱٫۷۹۲ = ln 6**: سر تصادفی به هر ۶ کلاس احتمال تقریباً برابر می‌دهد. دقت پیش از آموزش ۱۹٫۸٪ بود، نزدیک حدس تصادفی.

تنظیم	مقدار	چرا
learning rate	2e-5	کوچک، تا دانش قبلی مدل خراب نشود؛ کاهش خطی تا صفر
batch size	16	مناسب حافظهٔ GPU
epochs	3	آزمایش نشان داد ۵ دوره بهتر نیست
warmup	56 steps	۱۰٪ کل گام‌ها؛ سر تصادفی بدنه را به‌هم نریزد
weight decay	0.01	جلوگیری از بیش‌برازش
max_length	128	فقط ۱ متن از ۳۰۰۰ بریده می‌شود
گام‌ها	188 × 3 = 564	⌈۳۰۰۰÷۱۶⌉ گام در هر دوره

۵. آموزش مدل نهایی (Colab، Tesla T4، حدود ۳ دقیقه)

دوره	آموزش loss	اعتبارسنجی loss	اعتبارسنجی Macro-F1
1	0.8989	0.4524	0.8381
2	0.3410	0.3539	0.8765
3	0.1954	0.3426	0.8878

loss آموزش از حدود ۱٫۸ به حدود ۰٫۲ رسید، ولی loss اعتبارسنجی بعد از دورهٔ دوم تقریباً ثابت ماند (۰٫۳۵ ← ۰٫۳۴). فاصلهٔ رو به افزایش دو منحنی نشانهٔ شروع بیش‌برازش است، پس ۳ دوره کافی است.

دقت هر کلاس (مدل نهایی)

کلاس	precision	recall	f1
ورزش	0.990	1.000	0.995
سلامت	0.922	0.950	0.936
اقتصاد	0.887	0.860	0.873
علم و فناوری	0.838	0.880	0.859
بین‌الملل	0.827	0.860	0.843
سیاست	0.867	0.780	0.821
کل	**دقت 0.8883**		**0.8878**

ماتریس درهم‌ریختگی — سطر = واقعی، ستون = پیش‌بینی

	اقتصاد	بین‌الملل	سلامت	سیاست	علم	ورزش
اقتصاد	**86**	2	1	2	**9**	0
بین‌الملل	2	**86**	0	**8**	4	0
سلامت	3	0	**95**	0	2	0
سیاست	5	**14**	1	**78**	2	0
علم و فناوری	1	2	**6**	2	**88**	1
ورزش	0	0	0	0	0	**100**

۶. مقایسه با مدل‌های دیگر

مدل	دقت val	Macro-F1 val	اشتباه
BERT منجمد، فقط classifier (۵ دوره، lr=1e-3)	0.7717	0.7709	137
TF-IDF + LogisticRegression	0.8467	0.8463	92
ParsBERT فاین‌تیون کامل (نهایی)	**0.8883**	**0.8878**	**67**

- **فاین‌تیون در برابر TF-IDF:** ۴٫۲ واحد Macro-F1 بهتر و ۲۷٪ خطای کمتر. بیشترین بهبود در «علم و فناوری» (+۰٫۰۶۹) و «اقتصاد» (+۰٫۰۶۱) بود که با کلمهٔ کلیدی ساده جدا نمی‌شوند؛ کمترین در «سیاست» (+۰٫۰۲۷).
- **BERT منجمد:** حدود ۱۲ واحد افت، حتی ضعیف‌تر از TF-IDF. loss آموزش در همهٔ دوره‌ها از loss اعتبارسنجی بیشتر ماند، یعنی کم‌برازش: یک لایهٔ خطی روی نمایش‌های ثابت ظرفیت کافی ندارد. نمایش [CLS] بدون فاین‌تیون همان نمایش عمومی پیش‌آموزش است و pooler ِ تصادفی هم هرگز آموزش نمی‌بیند.

۷. تحلیل خطا

بیشترین اشتباه بین **سیاست و بین‌الملل** است (۱۴ + ۸ مورد). در TF-IDF هم همین جفت ۲۳ اشتباه داشت؛ مدل قوی‌تر این مشکل را حل نکرد.

کلمه در train	سیاست	بین‌الملل	نتیجه
مجلس	166	5	نشانهٔ روشن سیاست
عراق / روسیه	10 / 10	40 / 41	نشانهٔ روشن بین‌الملل
آمریکا	71	118	در هر دو زیاد
تحریم	30	25	در هر دو تقریباً برابر

نویز برچسب: در train خبرهایی کاملاً دربارهٔ آمریکا و چین برچسب «سیاست» دارند و خبرهایی دربارهٔ ایران برچسب «بین‌الملل». PN-Summary از چند خبرگزاری جمع شده و برچسب بیشتر به بخش خبرگزاری بستگی دارد تا به محتوای متن. خطای دوطرفه هم نشان می‌دهد مسئله سوگیری یک‌طرفهٔ مدل نیست، بلکه مرز این دو دسته مبهم است.

۸. آزمایش‌هایی که کمک نکردند

آزمایش	ایده	نتیجه روی val
۵ دوره و lr=3e-5	آموزش بیشتر	88.33% ← 88.00% **بدون بهبود**
balance.py	برابر کردن تعداد پیش‌بینی هر کلاس (Sinkhorn)	89.67% ← 89.00% **ضرر**
knn_fix.py	برچسب نزدیک‌ترین خبر تقریباً تکراری در train	بدون تغییر؛ BERT همه را از قبل درست گفته بود
TAPT (tapt.py)	ادامهٔ پیش‌آموزش MLM روی متن خبرها	یک مدل: ۷۰ اشتباه؛ در محدودهٔ نوسان، نتیجهٔ قطعی ثبت نشد

اجراهای مختلف فاین‌تیون کامل، فقط با تفاوت seed یا سخت‌افزار، بین **۸۷٫۵٪ و ۸۹٫۷٪** دقت داشتند (۶۲ تا ۷۵ اشتباه). پس اختلاف‌های کمتر از حدود ۱٫۵٪ روی ۶۰۰ نمونهٔ val قابل اتکا نیستند.

۹. درس‌ها

- **پاسخ را از خروجی کد بگیر، نه از حدس.** انتظار داشتیم توکنایزرِ «zwnj» نیم‌فاصله را نگه دارد؛ خروجی نشان داد حذفش می‌کند.
- **هیچ ترفندی را بدون اندازه‌گیری قبول نکن.** balance و knn منطقی بودند ولی کمک نکردند.
- **نوسان تصادفی بزرگ است**؛ برای مقایسهٔ روش‌ها چند اجرا یا ensemble لازم است.
- **هر اجرا خروجی‌اش را جدا نگه دارد.** یک آزمایش جانبی فایل پیش‌بینی مدل نهایی را بازنویسی کرد؛ کد اصلاح شد تا هر اجرا در پوشهٔ خودش ذخیره کند.
- **سقف را داده تعیین می‌کند.** با این برچسب‌ها، دقت بالای حدود ۹۰٪ بعید است.

۱۰. فایل‌های پروژه

فایل	کار
train.py	آموزش، ارزیابی، جدول دوره‌ها، نمودار یادگیری، پیش‌بینی test
part1_tokenizer.py	بررسی توکنایزر و توزیع طول‌ها
part4_analysis.py	احتمال جمله‌های مرزی و تحلیل اشتباه‌ها
baseline_tfidf.py	مدل پایهٔ TF-IDF
ensemble.py	ترکیب چند اجرا
tapt.py	پیش‌آموزش روی متن خبرها
find_label_errors.py	یافتن برچسب‌های مشکوک با k-fold
balance.py / knn_fix.py	پس‌پردازش (روی این داده کمک نکردند)

```
python train.py --output_dir outputs_report        # final model
python baseline_tfidf.py                            # TF-IDF baseline
python train.py --freeze_bert --lr 1e-3 --epochs 5 --output_dir outputs_frozen
python part1_tokenizer.py
python part4_analysis.py --model_dir outputs_report/best_model
```